



UNIVERZITET U NOVOM SADU
PRIRODNO-MATEMATIČKI FAKULTET
DEPARTMAN ZA MATEMATIKU
I INFORMATIKU



Andrija Stamenković
Jovana Savić

Efikasnost avio kompanije u popunjavanju dostupnih sedišta

- seminarski rad -

Mentor:
dr Sanja Ružičić

Novi Sad, Septembar 2023.

Sadržaj

1	Uvod	1
2	Jednostruki linearni model	8
3	Pun linearni model	11
4	Redukovani linearni model	13
5	Nelinearni modeli	16
6	Trening i testiranje	20
7	Zaključak	22
A	MATLAB kod	23
B	Osnovna tvrđenja	41
	Literatura	46


1 Uvod

Posmatraju se podaci o operacijama i učinku jedne avio kompanije. Oni se odnose na:


1. broj letova,
2. broj sati letenja,
3. broj pređenih kilometara u hiljadama,
4. broj putnika,
5. broj putničkih kilometara u hiljadama,
6. broj kilometara dostupnih sedišta (proizvod dostupnih sedišta u avionu i pređenog rastojanja) u hiljadama i
7. procenat zauzetih sedišta od onih koja su bila dostupna u avionu.

Podaci su dati po mesecima počevši od Aprila 2014. pa do Februara 2023. fiskalne godine koja počinje u Aprilu. Veličina uzorka je $n = 119$.


Gornjih sedam promenljivih su prikazane stubastim grafikonima na Slikama 1.1 - 1.7, gde su njihove vrednosti date hronološki po mesecima.



Slika 1.1: Broj letova tokom meseca




Slika 1.2: Broj sati letenja tokom meseca




Slika 1.3: Broj pređenih kilometara u hiljadama tokom meseca

Aprila 2021. fiskalne godine je, zbog pandemije COVID-19, došlo do naglog pada svih datih promenljivih na nulu, nakon čega je došlo do oporavka. Prvih šest promenljivih su se u narednih skoro tri godine vratile na nivo manji od prethodnog. Jedini izuzetak je sedma promenljiva, procenat zauzetih sedišta, za koju su na kraju tog perioda zabeležene vrednosti veće od svih prethodnih.

1 UVOD




Slika 1.4: Broj putnika tokom meseca




Slika 1.5: Broj putničkih kilometara u hiljadama tokom meseca

Za date promenljive su nađeni srednja vrednost (aritmetička sredina), minimum, prvi kvartil, medijana (tj. drugi kvartil), treći kvartil, maksimum, moda sa njenom učestalošću pojavljivanja, popravljena varijansa (tj. disperzija), popravljeno standardno odstupanje i međukvartilni opseg. Rezultati su, respektivno, dati na Slikama 1.8-1.18 po kolonama, gde broj kolone odgovara

1 UVOD




Slika 1.6: Broj kilometara dostupnih sedišta u hiljadama tokom meseca



Slika 1.7: Procenat zauzetih sedišta tokom meseca

rednom broju promenljive na listi sa početka ovog poglavlja.

Na primer, medijana četvrte promenljive, broj putnika, iznosi 1043708. Što se tiče mode, promenljiva u kojoj se svaka vrednost javlja najviše jedanput nema modu, pa je povratna vrednost NaN (od engleskog *Not a Number*). Radi preglednosti, svi rezultati su prikazani u jednoj matrici dobijene pomoću




mean_arr

1x7 double

	1	2	3	4	5	6	7
1	8.2477e+03	1.5212e+04	8.8106e+03	9.8924e+05	9.7888e+05	1.2693e+06	75.0319

Slika 1.8: Srednja vrednost (aritmetička sredina)




min_arr

1x7 double

	1	2	3	4	5	6	7
1	0	0	0	0	0	0	0

Slika 1.9: Minimum




quart1_arr

1x7 double

	1	2	3	4	5	6	7
1	7.6403e+03	1.4167e+04	7.7175e+03	8.5337e+05	8.6774e+05	1.1923e+06	71.2500

Slika 1.10: Prvi kvartil




med_arr

1x7 double

	1	2	3	4	5	6	7
1	8732	15493	9018	1043708	1015279	1291584	78.1000

Slika 1.11: Medijana (tj. drugi kvartil)




quart3_arr

1x7 double

	1	2	3	4	5	6	7
1	9.5223e+03	1.7674e+04	10379	1.2336e+06	1196767	1.4743e+06	81.7750

Slika 1.12: Treći kvartil



max_arr

1x7 double

	1	2	3	4	5	6	7
1	11262	2.1297e+04	1.2334e+04	1429384	1387335	1.7368e+06	89.3000

Slika 1.13: Maksimum

(programerske) funkcije `nancat` koja vrši konkatenaciju matrica po željenoj dimenziji i na praznim mestima ispisuje NaN (videti Algoritam A.3). Prema tome, sedma promenljiva, procenat zauzetih sedišta, je multimodalna, jer moda uzima vrednosti 77, 79.4, 79.6 i 81.8 po 3 puta.

Dodatno, izračunati su uzorački koeficijenti korelacije. Rezultati su prika-

	1	2	3	4	5	6	7
1	8753	NaN	NaN	NaN	NaN	NaN	77
2	9921	NaN	NaN	NaN	NaN	NaN	79.4000
3	10377	NaN	NaN	NaN	NaN	NaN	79.6000
4	NaN	NaN	NaN	NaN	NaN	NaN	81.8000

Slika 1.14: Moda

	1	2	3	4	5	6	7
1	2	1	1	1	1	1	3

Slika 1.15: Učestalost pojavljivanja mode

	1	2	3	4	5	6	7
1	4.1457e+06	1.4229e+07	4.5485e+06	9.4037e+10	8.1553e+10	9.1980e+10	129.4290

Slika 1.16: Popravljen varijansa (tj. disperzija)

	1	2	3	4	5	6	7
1	2.0361e+03	3.7722e+03	2.1327e+03	3.0666e+05	2.8557e+05	3.0328e+05	11.3767

Slika 1.17: Popravljen standardno odstupanje

	1	2	3	4	5	6	7
1	1882	3.5060e+03	2.6615e+03	380228	3.2902e+05	2.8197e+05	10.5250


Slika 1.18: Međukvartilni opseg

zani na Slici 1.19, gde broj kolone, odnosno vrste, odgovara rednom broju promenljive na listi.

Na primer, uzoračka korelacija između prve i četvrte promenljive, tj. broja letova i broja putnika, je 0.9462. Kao što je poznato, korelacija promenljive sa samom sobom je 1 i ona je simetrična, tj. redosled para promenljivih ne utiče na rezultat. Za sedmu promenljivu, tj. procenat zauzetih sedišta, uzorački koeficijenti korelacije uzimaju vrednosti između 0.74 i 0.85, dok su sve ostale vrednosti veće od 0.92.

Urađen je još i Pirsonov hi-kvadrat test da bi se ispitalo da li date pro-


1 UVOD



	1	2	3	4	5	6	7
1	1	0.9818	0.9323	0.9462	0.9402	0.9818	0.7467
2	0.9818	1	0.9509	0.9573	0.9601	0.9912	0.7642
3	0.9323	0.9509	1	0.9288	0.9289	0.9584	0.7468
4	0.9462	0.9573	0.9288	1	0.9938	0.9584	0.8245
5	0.9402	0.9601	0.9289	0.9938	1	0.9648	0.8486
6	0.9818	0.9912	0.9584	0.9584	0.9648	1	0.7737
7	0.7467	0.7642	0.7468	0.8245	0.8486	0.7737	1

Slika 1.19: Uzorački koeficijenti korelacije parova promjenljivih

menljive imaju normalnu raspodelu. Rezultati su prikazani na Slici 1.20, gde broj kolone odgovara rednom broju promenljive na listi. U prvom redu je broj prihvaćene hipoteze, gde broj 0 znači da je prihvaćena nulta hipoteza, tj. da posmatrana promenljiva ima normalnu raspodelu, dok broj 1 znači da je prihvaćena alternativna hipoteza, tj. da posmatrana promenljiva nema normalnu raspodelu, na nivou značajnosti 0.05. U drugom redu je odgovarajuća p -vrednost.



	1	2	3	4	5	6	7
1	1	1	1	0	1	1	1
2	6.4390e-05	0.0011	0.0026	0.0678	0.0154	4.3976e-06	0.0019

Slika 1.20: Rezultati Pirsonovog hi-kvadrat testa

Kao što se može videti sa gornje slike, jedino je za četvrtu promenljivu, broj putnika, prihvaćena nulta hipoteza.

U nastavku je ispitivana efikasnost avio kompanije u popunjavanju dostupnih sedišta, pa je sedma promenljiva uzeta za zavisnu, a ostale promenljive za nezavisne.

2 Jednostruki linearni model

Kao što je viđeno u prethodnom poglavlju (Slika 1.19), sedma promenljiva ima najveći koeficijent korelacije sa petom promenljivom. Stoga, posmatra se jednostruki linearni model


$$Y = \beta_0 + \beta_1 x_5 + \varepsilon,$$

gde je zavisna promenljiva Y procenat zauzetih sedišta, nezavisna promenljiva x_5 broj putničkih kilometara u hiljadama, β_0 i β_1 parametri koje treba oceniti i ε slučajna greška.

Ocene parametara β_0 i β_1 su dobijene metodom najmanjih kvadrata koji je izveden u Dodatku B. Takođe, za svaki tako dobijeni linearni model sa odsečkom (eng. *intercept*) se u daljem tekstu pretpostavlja da je očekivana vrednost slučajne greške jednaka nuli. Jednačina linearne regresije jednostrukog modela za procenat zauzetih sedišta preko broja putničkih kilometara u hiljadama je

$$\hat{Y} = 41.93899569 + 0.00003381x_5.$$

Dijagram rasipanja i regresiona prava su prikazani na Slici 2.1.




Slika 2.1: Dijagram rasipanja i regresiona prava jednostrukog linearnog modela

Bitna pretpostavka nekih statističkih testova i intervala poverenja je da reziduali imaju normalnu raspodelu. Oдавde sledi da bi podaci nezavisne

promenljive trebali da budu saglasni sa njom. Kao što je viđeno na kraju prethodnog poglavlja, ova pretpostavka nije ispunjena na nivou značajnosti 0.05. S obzirom na to, zaključke i rezultate kod kojih ova pretpostavka igra bitnu ulogu treba uzeti sa rezervom.

Ispunjenost pretpostavke o homoskedastičnosti reziduala je ispitana pomoću studentizovanog Bruš-Peiganovog testa (videti [1, 5]). Za njegovu implementaciju u Matlab-u videti Algoritam A.5. Pošto je izabrana studentizovana verzija, pretpostavlja se da su greške nezavisne i identično raspodeljene¹. Nulta hipoteza ovog testa je da su reziduali homoskedastični, a alternativna hipoteza je da su oni heteroskedastični (tj. nisu homoskedastični). Dobijena p -vrednost je $2.0505 \cdot 10^{-4}$, što je (strogo) manje od 0.05, pa se na nivou poverenja 0.95 zaključuje da su reziduali heteroskedastični.

Dijagram rasipanja reziduala posmatranog modela u odnosu na ocenu zavisne promenljive je prikazan na Slici 2.2. Sa nje se takođe može primetiti heteroskedastičnost reziduala.



Slika 2.2: Dijagram rasipanja reziduala jednogstrukog linearnog modela

Interval poverenja na nivou 0.95 za parametar β_0 je

$$\left[\hat{\beta}_0 - q\sqrt{\hat{D}(\hat{\beta}_0)}, \hat{\beta}_0 + q\sqrt{\hat{D}(\hat{\beta}_0)} \right],$$

gde je $\hat{\beta}_0$ ocena parametra β_0 , q kvantil reda 0.975 Studentove raspodele sa

¹u originalnoj verziji se pretpostavlja da je raspodela normalna

2 JEDNOSTRUKI LINEARNI MODEL

$n - 2$ stepeni slobode i $\hat{D}(\hat{\beta}_0)$ ocena disperzije $\hat{\beta}_0$. Dobijeni interval poverenja na nivou 0.95 za parametar β_0 je

$$[38.00572262, 45.87226876].$$

Analogno, interval poverenja na nivou 0.95 za parametar β_1 je

$$\left[\hat{\beta}_1 - q\sqrt{\hat{D}(\hat{\beta}_1)}, \hat{\beta}_1 + q\sqrt{\hat{D}(\hat{\beta}_1)} \right],$$

gde je $\hat{\beta}_1$ ocena parametra β_1 , q kvantil reda 0.975 Studentove raspodele sa $n - 2$ stepeni slobode i $\hat{D}(\hat{\beta}_1)$ ocena disperzije $\hat{\beta}_1$. Dobijeni interval poverenja na nivou 0.95 za parametar β_1 je

$$[0.00002995, 0.00003767].$$

Da bi se odredili intervali poverenja za parametre β_0 i β_1 , potrebno je da važi pretpostavka o homoskedastičnosti reziduala i da oni imaju normalnu raspodelu. Kako to nije ispunjeno, ne može se tvrditi da su dobijeni intervali poverenja odgovarajući.

Srednja kvadratna greška (eng. *mean squared error*) je definisana sa $MSE = RSS/n$, gde je RSS suma kvadrata reziduala. Kako je minimizacija srednje kvadratne greške ekvivalentna minimizaciji sume kvadrata reziduala, ona je u daljem tekstu korišćena za evaluaciju modela. U ovom slučaju ona iznosi 35.9167.

Koeficijent determinacije je 0.7201. Pošto je on blizu 1, može se reći da je veći deo varijabilnosti zavisne promenljive objašnjen modelom.

Pored ovog, nađeni su i ostali jednostruki linearni modeli sa odsečkom. Za sve njih je utvrđeno da postoji linearna veza između odgovarajuće nezavisne promenljive i procenta zauzetih sedišta, na nivou poverenja 0.95. Naravno, ove rezultate treba uzeti sa rezervom, jer samo broj putnika ima normalnu raspodelu i reziduali su u svim slučajevima heteroskedastični prema studentizovanom Bruš-Peiganovom testu, oba na nivou poverenja 0.95. Dodatno, izračunate su srednje kvadratne greške i koeficijenti determinacije svih modela, gde se kao najbolji pokazao model predstavljen u ovom poglavlju. S obzirom na to da je koeficijent determinacije jednak kvadratu uzoračkog koeficijenta korelacije, ovaj rezultat je bio očekivan (videti i Posledicu B.3 (i)).

3 Pun linearni model

Kako postoji linearna veza između datih promenljivih, posmatra se višestruki linearni model

$$Y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + \beta_6 x_6 + \varepsilon,$$


gde su sa x_1 do x_6 označene nezavisne promenljive tim redom kojim se javljaju na listi sa početka Poglavlja 1, zavisna promenljiva Y je procenat zauzetih sedišta, β_0 do β_6 su parametri koje treba oceniti i ε slučajna greška.

Neka su sa X_1 do X_6 označeni odgovarajući uzorci nezavisnih promenljivih x_1 do x_6 , respektivno. Tada je rang matrice $X = [1_{n \times 1} \ X_1 \ \dots \ X_6]$ jednak 7. Odavde sledi da se parametri linearne regresije koja modeluje procenat zauzetih sedišta preko ostalih šest promenljivih i odsečka, ili bilo kog njihovog podskupa, mogu oceniti na jedinstven način metodom najmanjih kvadrata.

Tako je dobijena jednačina linearne regresije punog modela za procenat zauzetih sedišta preko ostalih promenljivih

$$\begin{aligned} \hat{Y} = & 43.79588813 + 0.00552488x_1 - 0.00141099x_2 + 0.00149182x_3 \\ & - 0.00009411x_4 + 0.00016416x_5 - 0.00005799x_6. \end{aligned}$$

Studentizovani Bruš-Peiganov test daje p -vrednost $2.8601 \cdot 10^{-5}$, što je (strogo) manje od 0.05, pa se na nivou poverenja 0.95 zaključuje da su reziduali heteroskedastični.



Slika 3.1: Dijagram rasipanja reziduala punog linearnog modela

3 PUN LINEARNI MODEL

Na Slici 3.1 je prikazan dijagram rasipanja reziduala posmatranog modela u odnosu na ocenu zavisne promenljive.

Srednja kvadratna greška ovog modela je 25.8121, a koeficijent determinacije je 0.7989, što je dosta bolje od jednostrukog modela. Očekivano, koeficijent determinacije raste sa porastom broja promenljivih (Posledica B.5).

4 Redukovani linearni model

Čest problem punog modela je taj što on može da sadrži nezavisne promenljive koje nisu relevantne ili su redundantne. U tom slučaju je potrebno uzeti podskup datih promenljivih takav da model dobijen preko njih ima slične performanse. Na ovaj način se uspešnim odabirom promenljivih mogu izbeći problemi koji se javljaju u višedimenzionalnim prostorima, ubrzati izračunavanja i poboljšati predviđanja [3].

Postoje razni algoritmi za odabir promenljivih. Jedan od njih je „odabir odlika ka napred” (eng. *forward feature selection*), koji je ovde primenjen za linearni model i ocenu performansi preko sume kvadrata reziduala. Ovaj algoritam polazi od modela koji sadrži samo odsečak. Nakon toga se traži promenljiva takva da njenim dodavanjem novodobijeni model ima najmanju sumu kvadrata reziduala. Da bi model dobijen na takav način bio izabran, neophodno je da njegova suma kvadrata reziduala bude značajno manja od sume kvadrata reziduala prethodno izabranog modela. U tu svrhu se radi F-test. Ako je razlika suma kvadrata reziduala statistički značajna, onda posmatranu promenljivu dodajemo u skup izabranih. Ovaj postupak se ponavlja do prve razlike koja nije statistički značajna, ili dok se ne iskoriste sve promenljive.

Preciznije, ako je RSS suma kvadrata reziduala izabranog modela, a RSS_c suma kvadrata reziduala novog modela dobijenog dodavanjem jedne, do sada nekorisćene, promenljive, onda važi

$$\frac{RSS - RSS_c}{\frac{RSS_c}{n - k}} : F_{1, n-k},$$

ako reziduali imaju normalnu raspodelu, gde je k broj ocenjenih parametara novog modela. Za implementaciju u Matlab-u videti Algoritam A.7.

Kao što je već rečeno, pošto nije ispunjena pretpostavka o normalnoj raspodeli reziduala, rezultate gornjeg statističkog testa treba uzeti sa rezervom.

Neka je procenat zauzetih sedišta zavisna promenljiva, ostale promenljive nezavisne i nivo značajnosti 0.05. Promenljive izabrane primenom ovog algoritma su broj putničkih kilometara u hiljadama, broj sati letenja i broj putnika, tim redom.

Prema tome, posmatra se višestruki linearni model

$$Y = \beta_0 + \beta_1 x_5 + \beta_2 x_2 + \beta_3 x_4 + \varepsilon,$$

gde su x_5 , x_2 i x_4 nezavisne promenljive u gore navedenom redosledu, zavisna promenljiva Y procenat zauzetih sedišta, β_0 do β_3 parametri koje treba


4 REDUKOVANI LINEARNI MODEL

oceniti i ε slučajna grešaka. Metodom najmanjih kvadrata su dobijene ocene parametara β_0 do β_3 . Jednačina linearne regresije redukovano modela za procenat zauzetih sedišta preko izabranih promenljivih je

$$\hat{Y} = 44.07230816 + 0.00011081x_5 - 0.00177392x_2 - 0.00005108x_4.$$

Primenom studentizovanog Bruš-Peiganovog testa se dobija p -vrednost $1.2182 \cdot 10^{-5}$, što je (strogo) manje od 0.05, pa se na nivou poverenja 0.95 zaključuje da su reziduali heteroskedastični.

Dijagram rasipanja reziduala redukovano modela u odnosu na ocenu procenat zauzetih sedišta prikazan na Slici 4.1.



Slika 4.1: Dijagram rasipanja reziduala redukovano modela

Srednja kvadratna greška ovog modela je 28.7738, a koeficijent determinacije je 0.7758, što je malo lošije od punog modela.

Prirodno se postavlja pitanje da li pun model daje značajno bolje ocene zavisne promenljive od redukovano modela. Da bi se to ispitalo, testira se nulta hipoteza $H_0(\beta^{izb} = 0_{h \times 1})$, gde je β^{izb} vektor parametara koji su izbačeni iz punog modela i h njihov broj, protiv alternativne $H_1(\beta^{izb} \neq 0_{h \times 1})$, koristeći test statistiku

$$\frac{\frac{RSS^{red} - RSS}{h}}{\frac{RSS}{n - k}} = F_{reg},$$

gde je RSS^{red} suma kvadrata reziduala redukovano, a RSS punog modela i

k broj ocenjenih parametara punog modela. Nulta hipoteza $H_0(\beta^{izb} = 0_{h \times 1})$ se odbacuje ako je $F_{reg} > q$, gde je q kvantil reda 0.95 Fišerove raspodele sa h i $n - k$ stepeni slobode. U ovom slučaju je $h = 3$, $n - k = 112$ i $F_{reg} = 4.2837 > 2.6856 = q$. To znači da se nulta hipoteza $H_0(\beta^{izb} = 0_{h \times 1})$ odbacuje na nivou poverenja 0.95, odnosno pun model pruža značajno bolje prilagođavanje podacima od redukovanog modela.


5 Nelinearni modeli

Pošto procenat zauzetih sedišta može da uzima vrednosti samo između 0 i 100, a linearna funkcija nije ograničena, linearni modeli daju vrednosti van tog intervala, što nema realnog smisla (videti [7] za poznati primer sa sličnim problemom). Ovo motiviše pravljenje regresionog modela pomoću nelinearne funkcije. Poželjno je da ona uzima vrednosti samo od 0 do 100 i da joj domen nije ograničen odozgo (jer ostale nezavisne promenljive nisu ograničene odozgo). Ne postoji egzaktna procedura za odabir funkcije, pa intuicija za njen izbor dolazi i sa dijagrama rasipanja (videti Sliku 2.1).

Jedna funkcija koja odgovara gornjem opisu je

$$L(x) = \frac{100}{1 + e^{-x}},$$

čija je skica grafika data na Slici 5.1, gde je $y = L(x)$.



Slika 5.1: Skica grafika $y = \frac{100}{1 + e^{-x}}$

Kako je domen funkcije L ceo skup realnih brojeva, njen argument može biti bilo koji realan broj, pa se može uzeti linearna kombinacija nezavisnih promenljivih i konstante. Konkretno, za jednostruki nelinearni model ta linearna kombinacija je $\beta_0 + \beta_1 x_5$, gde je x_5 broj putničkih kilometara u hiljadama, a β_0 i β_1 su parametri koje treba oceniti. Stoga, posmatra se

jednostruki nelinearni model

$$Y = L(\beta_0 + \beta_1 x_5) + \varepsilon = \frac{100}{1 + e^{-(\beta_0 + \beta_1 x_5)}} + \varepsilon,$$

gde je zavisna promenjiva Y procenat zauzetih sedišta i ε slučajna greška.

Ocene parametara β_0 i β_1 su dobijene metodom najmanjih kvadrata koristeći Gaus-Njutnov postupak (za više detalja videti [4]). Prilikom njegove primene, parcijalni izvodi u Jakobijanu su aproksimirani pomoću numeričkog postupka koji se naziva diferenciranje kompleksnim korakom (eng. *Complex Step Differentiation*). Naime, ako su $r_i, i \in \{1, 2, \dots, n\}$, holomorfne funkcije¹ koje uzimaju realne vrednosti za $\mathbf{x} \in \mathbb{R}^k$, $\mathbf{r} = [r_1 \ r_2 \ \dots \ r_n]^T$ i $J_{\mathbf{r}}(\mathbf{x})$ Jakobijan od $\mathbf{r}$ u tački $\mathbf{x}$, onda važi

$$J_{\mathbf{r}}(\mathbf{x}) \approx \frac{1}{h} \Im \begin{bmatrix} r_1(\mathbf{x} + i h \mathbf{e}_1) & r_1(\mathbf{x} + i h \mathbf{e}_2) & \dots & r_1(\mathbf{x} + i h \mathbf{e}_k) \\ r_2(\mathbf{x} + i h \mathbf{e}_1) & r_2(\mathbf{x} + i h \mathbf{e}_2) & \dots & r_2(\mathbf{x} + i h \mathbf{e}_k) \\ \vdots & \vdots & & \vdots \\ r_n(\mathbf{x} + i h \mathbf{e}_1) & r_n(\mathbf{x} + i h \mathbf{e}_2) & \dots & r_n(\mathbf{x} + i h \mathbf{e}_k) \end{bmatrix},$$

gde je h korak, $\mathbf{e}_j$ j -ta kolona jedinične matrice $\mathbf{E}_{k \times k}$, $j \in \{1, 2, \dots, k\}$, i $\Im$ imaginarni deo kompleksnog broja. Dokaz prethodnog se može naći, na primer, u [6]. Za implementaciju Gaus-Njutnovog postupka (gde je korišćena navedena aproksimacija parcijalnih izvoda) u Matlab-u videti Algoritam A.10.

Jasno je da se gore navedeno može primeniti na posmatrani model da bi se dobile ocene parametara β_0 i β_1 . Neka je $\beta = [\beta_0 \ \beta_1]^T$. Uzimajući za početak Gaus-Njutnovog postupka $\hat{\beta}_{(0)} = 0_{2 \times 1}$, korak aproksimacije parcijalnih izvoda $h = 10^{-11}$, maksimalan broj iteracija 100 i uslov zaustavljanja $\|\hat{\beta}_{(s)} - \hat{\beta}_{(s+1)}\|_2 < 10^{-11}$, gde je s (s) u indeksu označen s -ti korak, $s \in \{0, 1, \dots, 99\}$, dobija se


$$\hat{\beta} = \begin{bmatrix} -0.52146894 \\ 0.00000172 \end{bmatrix}.$$

Dakle, jednačina nelinearne regresije jednostrukog modela za procenat zauzetih sedišta preko broja putničkih kilometara u hiljadama je

$$\hat{Y} = \frac{100}{1 + e^{0.52146894 - 0.00000172 x_5}}.$$

Dijagram rasipanja i regresiona kriva su prikazani na Slici 5.2.

¹tj. funkcije koje su kompleksno diferencijabilne u svakoj tački posmatranog otvorenog skupa



Slika 5.2: Dijagram rasipanja i regresiona kriva jednostrukog nelinearnog modela

Srednja kvadratna greška jednostrukog nelinearnog modela je 30.7402, što je bolje od odgovarajućeg linearnog modela.

Analogno, posmatraju se pun i redukovani višestruki nelinearni modeli

$$Y = \frac{100}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5 + \beta_6 x_6)}} + \varepsilon,$$

$$Y = \frac{100}{1 + e^{-(\beta_0 + \beta_1 x_5 + \beta_2 x_2 + \beta_3 x_4)}} + \varepsilon,$$

respektivno, gde su sa x_1 do x_6 označene nezavisne promenljive tim redom kojim se javljaju na listi sa početka Poglavlja 1, zavisna promenljiva Y je procenat zauzetih sedišta, u prvom slučaju β_0 do β_6 , a u drugom β_0 do β_3 , su parametri koje treba oceniti i ε slučajna greška, u oba slučaja. Bitno je napomenuti da redukovani nelinearni model koristi nezavisne promenljive izabrane u prethodnom poglavlju za redukovani linearni model. Dakle, nije vršena redukcija koja odgovara nelinearnom modelu.

Ocene parametara oba modela su dobijene metodom najmanjih kvadrata koristeći Gaus-Njutnov postupak na isti način kao kod ocene parametara jednostrukog nelinearnog modela. Jednačina nelinearne regresije punog modela

za procenat zauzetih sedišta preko ostalih promenljivih je

$$\hat{Y} = 100 / (1 + \exp(0.35680833 - 0.00019237x_1 + 0.00006123x_2 - 0.00009314x_3 + 0.00000424x_4 - 0.00000782x_5 + 0.00000269x_6)).$$

Jednačina nelinearne regresije redukovanog modela za procenat zauzetih sedišta preko promenljivih izabranih u prethodnom poglavlju je

$$\hat{Y} = \frac{100}{1 + e^{0.35221238 - 0.00000559x_5 + 0.00010635x_2 + 0.00000236x_4}}.$$

Srednja kvadratna greška punog nelinearnog modela je 22.5393, a redukovanog je 24.1371, što je u oba slučaja bolje od odgovarajućih linearnih modela.

Pošto nije vršena redukcija nezavisnih promenljivih koja odgovara nelinearnom modelu, može se desiti da je slobodan član u eksponentu suvišan za unapred dat podskup nezavisnih promenljivih. To će biti ispitano samo u slučaju nezavisnih promenljivih izabranih za redukovani linearni model, a rezultat ove odluke će biti evaluiran u sledećem poglavlju. Prema tome, posmatra se redukovani višestruki nelinearni model bez slobodnog člana

$$Y = \frac{100}{1 + e^{-(\beta_1 x_5 + \beta_2 x_2 + \beta_3 x_4)}} + \varepsilon,$$

gde su oznake iste kao malopre.

Ocene parametara su dobijene metodom najmanjih kvadrata koristeći Gaus-Njutnov postupak na isti način kao u prethodna tri slučaja. Jednačina nelinearne regresije redukovanog modela bez slobodnog člana za procenat zauzetih sedišta preko broja putničkih kilometara u hiljadama, broja sati letenja i broja putnika, tokom meseca, je

$$\hat{Y} = \frac{100}{1 + e^{-0.00000514x_5 + 0.00015471x_2 + 0.00000152x_4}}.$$

Srednja kvadratna greška redukovanog nelinearnog modela bez slobodnog člana je 26.8485.

6 Trening i testiranje

Podela podataka na trening i testiranje se koristi da bi se ocenile performanse predviđanja modela. Takođe, na ovaj način mogu da se uporede performanse predviđanja više modela.

Skup svih dostupnih podataka se, na slučajan način, deli na dva dela. Prvi deo, koji se uglavnom uzima da bude oko 70% podataka, služi za pravljenje modela, što se naziva trening ili obuka modela, a odgovarajući skup podataka se naziva trening skup ili skup za obuku. Drugi deo, koji čine preostali podaci, se ne koristi za obuku modela, umesto toga, na njemu se ocenjuju performanse modela dobijenog na trening skupu. Ovaj drugi deo podataka se naziva skup za testiranje.


Modeli se ovako koriste u praksi. Naime, oni se treniraju na skupu svi dostupnih podataka, a zatim se pomoću njih prave predviđanja za željene slučajeve koji ne moraju da se nalaze u tom skupu podataka.

Gore navedeni slučajan izbor podataka za trening skup se radi kako bi se osigurala njegova reprezentativnost datog skupa podataka, koji bi zauzvrat trebao da bude reprezentativan uzorak zapažanja iz domena posmatranog problema. Prilikom upoređivanja modela, neophodno je da se oni treniraju i testiraju na istim podskupovima datog skupa podataka.

Naravno, podela podataka na trening i testiranje ima smisla samo kada je dati skup podataka dovoljno velik [2].

Pored uslova da je moguće da se napravi model na trening skupu i on evaluiira na test skupu, ova procedura ne zahteva nikakve dodatne pretpostavke. Takođe, poželjno je da se ona ponovi više puta kako bi ocene performansi predviđanja bile što preciznije.

Konkretno, veličina datog skupa podataka je $n = 119$, pa se uzimanjem, na slučajan način, približno 70% podataka za trening skup dobija da je on veličine $n_{training} = 83$, pa je veličina test skupa $n_{test} = 36$. Trening i testiranje, na istim podacima, je urađeno za svih sedam modela iz prethodnih poglavlja. Procedura je ponovljena 1000 puta, a performanse predviđanja su ocenjene aritmetičkom sredinom srednjih kvadratnih grešaka na test skupovima. Dobijeni rezultati su prikazani na Slici 6.1 za svih sedam modela u redosledu njihovog pojavljivanja.



	1	2	3	4	5	6	7
1	41.6395	43.4323	40.8113	36.4007	39.5436	37.4221	27.0877

Slika 6.1: Aritmetička sredina srednjih kvadratnih grešaka na test skupovima

Kao što se može videti sa nje, redukovani nelinearni model bez slobodnog

člana ima najbolje performanse predviđanja, a za njim slede jednostruki nelinearni model, redukovani nelinearni model (sa slobodnim članom), pun nelinearni model, redukovani linearni model, jednostruki linearni model i pun linearni model, tim redom. Pored toga, svaki nelinearni model ocenjen je kao bolji od bilo kog linearnog.

Dakle, u praksi se za predviđanja koriste modeli dobijeni u prethodnim poglavljima na skupu svih dostupnih podataka, dok su njihove ocene performansi predviđanja date na Slici 6.1.

Bitno je napomenuti da procenat podataka za trening skup, slučajnost pri njihovom izboru i broj iteracija utiču na krajnji rezultat ove procedure.

7 Zaključak

Kako bi se predvidela efikasnost avio kompanije u popunjavanju dostupnih sedišta, posmatrana su sedam modela. Za sve njih su, između ostalog, nađene srednje kvadratne greške. Pored toga, kako bi se procenila njihova tačnost predviđanja, urađen je trening i testiranje gde je za ocenu performansi uzeta aritmetička sredina hiljadu srednjih kvadratnih grešaka. Prema tome, ima smisla uporediti ove rezultate. Oni su dati, na dve decimale, u tabeli ispod za svih sedam modela u redosledu njihovog pojavljivanja. Kao što se vidi sa nje,

MSE	35.92	25.81	28.77	30.74	22.54	24.14	26.85
a.s. test MSE	41.64	43.43	40.81	36.40	39.54	37.42	27.09

Tabela 7.1: Srednje kvadratne greške i njihove aritmetičke sredine na test skupovima za posmatrane modele

ocene performansi predviđanja svakog modela su lošije od njegove srednje kvadratne greške. Razlika je najveća kod punih modela, tj. onih modela koji koriste sve raspoložive nezavisne promenljive. Takođe, primećuje se da razlika opada sa smanjenjem broja nezavisnih promenljivih, gde je jedini izuzetak redukovani nelinearni model bez slobodnog člana. Zanimljivo je da je redukovani linearni model ocenjen kao bolji od punog linearnog modela prilikom treninga i testiranja, iako se pun model značajno bolje prilagođava podacima. Ova pojava, da se model suviše dobro prilagođava podacima na skupu za obuku, ali daje lošija predviđanja za nove podatke, se na engleskom naziva *overfitting*. Sa Tabele 7.1 se može videti da najmanje problema sa *overfitting*-om ima redukovani nelinearni model bez slobodnog člana. Pošto je on ocenjen kao ubedljivo najbolji, za realna predviđanja efikasnosti avio kompanije u popunjavanju dostupnih sedišta izabran je taj model.

Dodatak A MATLAB kod

Ispod je skripta pomoću koje su dobijene slike i rezultati korišćeni u Poglavlju 1.

```
1  at = readtable('AirTraffic.csv');
2
3  at{:, 1} = strrep(at{:, 1}, 'MAY', 'MAJ');
4  at{:, 1} = strrep(at{:, 1}, 'JUNE', 'JUN');
5  at{:, 1} = strrep(at{:, 1}, 'JULY', 'JUL');
6  at{:, 1} = strrep(at{:, 1}, 'AUG', 'AVG');
7  at{:, 1} = strrep(at{:, 1}, 'OCT', 'OKT');
8  at{:, 9} = strrep(at{:, 9}, 'Y', 'G');
9
10 oznake = {'letova', 'sati letenja', 'predjenih
    kilometara u hiljadama', 'putnika', 'putnickih
    kilometara u hiljadama', 'kilometara dostupnih
    sedista u hiljadama', 'Procenat zauzetih sedista'};
11
12 atnum = at{:, 2:8};
13 mask = notnanrow(atnum);
14 atnum = atnum(mask, :);
15
16 n = size(atnum, 1);
17 k = size(atnum, 2);
18
19 mo_fiscalyr = strcat(at{:, 1}, {' '}, at{:, 9});
20 x_axis = mo_fiscalyr(mask);
21 colors = {'b', 'g', 'r', 'c', 'm', 'y'};
22 fs = 22;
23 for j = 1:k - 1
24     figure
25     bar(atnum(:, j), 'BarWidth', 0.77, 'FaceColor',
        char(colors(j)))
26     set(gca, 'XTick', 1:n, 'XTickLabel', x_axis,
        'XTickLabelRotation', 90, 'TickLength', [0 0],
        'FontSize', 10.5)
27     txt = strcat({'Broj '}, oznake(j));
28     ylabel(char(txt), 'FontSize', fs)
29     title(char(strcat(txt, {' tokom meseca'})),
        'FontSize', fs)
```

A MATLAB KOD

```
30 end
31 figure
32 bar(atnum(:, k), 'BarWidth', 0.77)
33 set(gca, 'XTick', 1:n, 'XTickLabel', x_axis,
    'XTickLabelRotation', 90, 'TickLength', [0 0],
    'FontSize', 10.5)
34 ylabel(char(oznake(k)), 'FontSize', fs)
35 title(char(strcat(oznake(k), {' tokom meseca'})),
    'FontSize', fs)
36
37 mean_arr = mean(atnum);
38 min_arr = min(atnum);
39 quart1_arr = quantile(atnum, 0.25);
40 med_arr = median(atnum);
41 quart3_arr = quantile(atnum, 0.75);
42 max_arr = max(atnum);
43 mode_arr = [];
44 [~, freq_mode_arr, mode_cell] = mode(atnum);
45 for j = 1:k
46     if freq_mode_arr(j) > 1
47         mode_arr = nancat({mode_arr, mode_cell{j}},
            2);
48     else
49         mode_arr = nancat({mode_arr, NaN}, 2);
50     end
51 end
52 cvar_arr = var(atnum);
53 cstdev_arr = sqrt(cvar_arr);
54 iqr_arr = quart3_arr - quart1_arr;
55
56 Rho = corr(atnum);
57
58 HP = NaN(2, k);
59 for j = 1:k
60     [HP(1, j), HP(2, j)] = chi2gof(atnum(:, j));
61 end
```

Algoritam A.1: Projekat_Uvod.m

Jedna od funkcija koju koristi gornja skripta je `notnanrow`. Ona za ulaz uzima matricu i vraća vektor-kolonu logičkih (*bool*) vrednosti gde su sa 1

A MATLAB KOD

(*true*) označeni odgovarajući redovi koji ne sadrže NaN, a sa 0 (*false*) oni koji ga sadrže.

```
1  function [mask] = notnanrow(M)
2
3  n = size(M, 1);
4  k = size(M, 2);
5
6  mask = true(n, 1);
7  for i = 1:n
8      for j = 1:k
9          if isnan(M(i, j))
10             mask(i) = false;
11             break
12         end
13     end
14 end
15
16 end
```

Algoritam A.2: notnanrow.m

Druga funkcija korišćena u istoj skripti je **nancat**. Ona za ulaz uzima strukturu podataka nazvanu ćelija (eng. *cell*), koja sadrži matrice i redni broj dimenzije po kojoj se vrši konkatencija tih matrica, gde 1 odgovara konkatenciji matrica u kolonu, a 2 u vrstu, respektivno. Izlaz ove funkcije je matrica dobijena konkatencijom matrica iz ćelije po željenoj dimenziji tako da je na praznim mestima ispisano NaN.

```
1  function [M] = nancat(C, dim)
2
3  n = numel(C);
4
5  if dim == 2
6      cdim = 1;
7  else
8      cdim = 2;
9  end
10
11  maxcdim = 0;
12  accsumdim = zeros(1, n + 1);
```

A MATLAB KOD

```
13  for i = 1:n
14      if size(C{i}, cdim) > maxcdim
15          maxcdim = size(C{i}, cdim);
16      end
17
18      accsumdim(i + 1) = accsumdim(i) + size(C{i}, dim);
19  end
20
21  if dim == 2
22      M = NaN(maxcdim, accsumdim(n + 1));
23      for i = 1:n
24          M(1:size(C{i}, cdim), accsumdim(i) +
25              1:accsumdim(i + 1)) = C{i};
26      end
27  else
28      M = NaN(accsumdim(n + 1), maxcdim);
29      for i = 1:n
30          M(accsumdim(i) + 1:accsumdim(i + 1),
31              1:size(C{i}, cdim)) = C{i};
32      end
33  end
```

Algoritam A.3: nancat.m

Za linearnu regresiju korišćena je funkcija `lreg`. Njen ulaz čine matrica koja odgovara linearnom modelu i vektor-kolona uzorka zavisne promenljive tog modela, respektivno. Njen izlaz čine vektor-kolona ocena koeficijenata, vektor-kolona ocena uzorka zavisne promenljive i suma kvadrata reziduala, tim redom.

```
1  function [beta_hat, y_hat, RSS] = lreg(x, y)
2
3  beta_hat = (x' * x) \ (x' * y);
4  y_hat = x * beta_hat;
5  RSS = sum((y - y_hat) .^ 2);
6
7  end
```

Algoritam A.4: lreg.m

A MATLAB KOD

Za Bruš-Peiganov test korišćena je funkcija `bptest`. Ona za ulaz uzima matricu pomoćne linearne regresije, vektor-kolonu reziduala `i`, opciono, logičku (*bool*) vrednost za studentizaciju test statistike, čija je podrazumevana vrednost *true*. Njen izlaz je p -vrednost za Bruš-Peiganov test. Zbog svoje opštosti, pomoću ovako implementiranog Bruš-Peiganovog testa moguće je uraditi druge testove koji su njegov specijalan slučaj, na primer Vajtov test [9, 8]. Konkretno, kada se kaže da je urađen Bruš-Peiganov test, podrazumeva se da je matrica pomoćne linearne regresije ista ona matrica koja odgovara linearnom modelu.

```
1  function [p] = bptest(z, res, studentize)
2
3  if nargin == 2
4      studentize = true;
5  end
6
7  n = size(res, 1);
8
9  res2 = res .^ 2;
10 ML_S2 = sum(res2) / n;
11 g = res2 / ML_S2;
12 [~, g_hat] = lreg(z, g);
13
14 deg_fr = size(z, 2) - 1;
15 ESS = sum((g_hat - mean(g)) .^ 2);
16 if studentize
17     TSS = sum((g - mean(g)) .^ 2);
18     R2 = ESS / TSS;
19     test_stat = n * R2;
20 else
21     test_stat = ESS / 2;
22 end
23 p = 1 - chi2cdf(test_stat, deg_fr);
24
25 end
```

Algoritam A.5: `bptest.m`

Ispod je skripta pomoću koje su nađeni svi jednostruki linearni modeli sa odsečkom i njihove najvažnije osobine.

A MATLAB KOD

```
1  atnum = xlsread('AirTraffic.xlsx');
2  y = atnum(:, end);
3
4  n = size(atnum, 1);
5  k = size(atnum, 2) - 1;
6
7  deg_fr = n - 2;
8  SST = sum((atnum - repmat(mean(atnum), n, 1)) .^ 2);
9  q = tinv(0.975, deg_fr);
10
11  beta_hat = NaN(2, k);
12  RSS = NaN(1, k);
13  BP = NaN(1, k);
14  for j = 1:k
15      X = [ones(n, 1) atnum(:, j)];
16      [beta_hat(:, j), y_hat, RSS(j)] = lreg(X, y);
17
18      BP(j) = bptest(X, y - y_hat);
19
20      S2 = RSS(j) / deg_fr;
21      t_reg = beta_hat(2, j) / sqrt(S2 / SST(j));
22      if abs(t_reg) > q
23          disp(['Prihvatamo hipotezu H1 da postoji
24              linearna veza izmedju nezavisne promenljive
25              x', num2str(j), ' i zavisne promenljive Y,
26              na nivou poverenja 0.95.'])
27      else
28          disp(['Prihvatamo hipotezu H0 da ne postoji
29              linearna veza izmedju nezavisne promenljive
30              x', num2str(j), ' i zavisne promenljive Y,
31              na nivou poverenja 0.95.'])
32      end
33  end
34
35  MSE = RSS / n;
36  R2 = 1 - RSS / SST(end);
```

Algoritam A.6: Projekat_Jednostruki_Lin_Mod_Ukratko.m

„Odabir odlika ka napred”, za linearnu regresiju i ocenu performansi preko sume kvadrata reziduala, implementiran je pomoću funkcije `ffsb`. Njen

A MATLAB KOD

ulaz čine matrica koja odgovara punom linearnom modelu, vektor-kolona uzorka zavisne promenljive tog modela, redni broj kolone uzorka nezavisne promenljive koja čini bazu (što bi trebao da bude odsečak) i nivo značajnosti, respektivno. Njen izlaz čine vektor-kolona rednih brojeva izabranih kolona matrice koja odgovara punom linearnom modelu tako da je očuvan redosled izbora, vektor-kolona ocena koeficijenata izabradog modela, vektor-kolona ocena uzorka zavisne promenljive izabranog modela i suma kvadrata reziduala izabranog modela, tim redom.

```
1  function [feat, beta_hat, y_hat, RSS] = ffsb(x, y,  
    base, alpha)  
2  
3  n = size(y, 1);  
4  k = size(x, 2);  
5  
6  feat = base;  
7  [~, ~, RSS] = lreg(x(:, feat), y);  
8  for i = 2:k  
9      RSS_arr = NaN(k, 1);  
10     for j = 1:k  
11         if ~isin(j, feat)  
12             [~, ~, RSS_arr(j)] = lreg(x(:, [feat;  
                j]), y);  
13         end  
14     end  
15  
16     [RSS_c, feat_c] = min(RSS_arr);  
17     if (RSS - RSS_c) / (RSS_c / (n - i)) <= finv(1 -  
        alpha, 1, n - i)  
18         break  
19     end  
20  
21     feat = [feat; feat_c];  
22     RSS = RSS_c;  
23 end  
24  
25 [beta_hat, y_hat] = lreg(x(:, feat), y);  
26  
27 end
```

Algoritam A.7: ffsb.m

A MATLAB KOD

Prethodna funkcija koristi funkciju `isin`. Ona za ulaz uzima element `i` strukturu podataka, respektivno. Njen izlaz je logička (*bool*) vrednost 1 (*true*) ili 0 (*false*), u zavisnosti od toga da li data struktura podataka sadrži (na prvom nivou) element jednak (onako kako je to definisano u Matlab-u) zadatom elementu ili ne, respektivno.

```
1  function [bool] = isin(A, DS)
2
3  bool = false;
4  if isa(DS, 'cell')
5      for i = 1:numel(DS)
6          if isequal(A, DS{i})
7              bool = true;
8              break
9          end
10     end
11 elseif isa(DS, 'table') || isa(DS, 'timetable')
12     b = size(DS, 2);
13     for i = 1:size(DS, 1)
14         for j = 1:b
15             if isequal(A, DS{i, j})
16                 bool = true;
17                 break
18             end
19         end
20     end
21     if bool
22         break
23     end
24 else
25     for i = 1:numel(DS)
26         if isequal(A, DS(i))
27             bool = true;
28             break
29         end
30     end
31 end
32
33 end
```

Algoritam A.8: `isin.m`

A MATLAB KOD

Ispod je skripta pomoću koje je dobijena skica grafika funkcije korišćena u Poglavlju 5.

```
1  x = -5:0.1:5;
2  y = 100 ./ (1 + exp(-x));
3  plot(x, y, 'b')
4  xlabel('x')
5  ylabel('y')
6  title('y = 100 / (1 + exp(-x))')
```

Algoritam A.9: Projekat_Grafik.m

Gaus-Njutnov postupak je implementiran pomoću funkcije `gn`. Ona za ulaz uzima uzorak zavisne promenljive, funkciju po koeficijentima koje želimo da ocenimo i čije su konstante uzorak nezavisnih promenljivih dat po kolonama, vektor-kolonu za početak iterativnog postupka, korak za numeričku aproksimaciju parcijalnih izvoda u Jakobijanu, maksimalan broj iteracija i broj za uslov zaustavljanja, respektivno. Numerički postupak koji ova funkcija koristi za aproksimaciju parcijalnih izvoda se naziva diferenciranje kompleksnim korakom (eng. *Complex Step Differentiation*). Algoritam se zaustavlja pre nego što dostigne maksimalan broj iteracija ako je euklidska norma vektora-kolone koji se oduzima u Gaus-Njutnovom postupku (strogo) manja od broja za uslov zaustavljanja ili ona ne može da se izračuna (daje vrednost NaN). Izlaz ove funkcije čine vektor-kolona ocena koeficijenata, broj iteracija, vektor-kolona ocena uzorka zavisne promenljive i suma kvadrata reziduala, tim redom.

```
1  function [beta_hat, n_iter, y_hat, RSS] = gn(y, f,
      beta_hat, h, max_iter, stop)
2
3  n = size(y, 1);
4  r = @ (b) y - f(b);
5  n_param = size(beta_hat, 1);
6  M = 1i * h * eye(n_param);
7
8  J = NaN(n, n_param);
9  for n_iter = 1:max_iter
10     for j = 1:n_param
11         J(:, j) = imag(r(beta_hat + M(:, j))) / h;
12     end
13
14     g = (J' * J) \ (J' * r(beta_hat));
```

A MATLAB KOD

```
15     norm_g = norm(g);
16     if norm_g < stop || isnan(norm_g)
17         n_iter = n_iter - 1;
18         break
19     end
20
21     beta_hat = beta_hat - g;
22 end
23
24 y_hat = f(beta_hat);
25 RSS = sum((y - y_hat) .^ 2);
26
27 end
```

Algoritam A.10: gn.m

Ispod je skripta pomoću koje je urađeno skoro sve vezano za regresiju u ovom projektu.

```
1  atnum = xlsread('AirTraffic.xlsx');
2  X = atnum(:, 1:6);
3  y = atnum(:, 7);
4
5  n = size(y, 1);
6
7  alpha = 0.05;
8  gamma = 1 - alpha;
9
10 % ---- Jednostruki linearni model ----
11
12 X5 = atnum(:, 5);
13
14 X_jm = [ones(n, 1) X5];
15 [beta_jm_hat, y_jm_hat, RSS_jm] = lreg(X_jm, y);
16 disp(['Jednacina jednostruke linearne regresije za
      procenat zauzetih sedista preko broja putnickih
      kilometara * 1000, tokom meseca, je Y = ',
      num2str(beta_jm_hat(1)), ' + ',
      num2str(beta_jm_hat(2)), ' * x5.'])
17
18 figure
```

A MATLAB KOD

```
19 plot(X5, y, 'b*')
20 hold on
21 plot(X5, y_jm_hat, 'r')
22 xlabel('Broj putnickih kilometara u hiljadama')
23 ylabel('Procenat zauzetih sedista')
24 title(['Dijagram rasipanja i regresiona prava y = ',
        num2str(beta_jm_hat(1)), ' + ',
        num2str(beta_jm_hat(2)), ' * x'])
25 hold off
26
27 res_jm = y - y_jm_hat;
28 p_jm = bptest(X_jm, res_jm);
29 if p_jm < alpha
30     disp(['Reziduali jednostrukog linearnog modela
        nisu homoskedasticni prema studentizovanom
        Brus-Peiganovom testu na nivou poverenja ',
        num2str(gamma), '.'])
31 else
32     disp(['Reziduali jednostrukog linearnog modela su
        homoskedasticni prema studentizovanom
        Brus-Peiganovom testu na nivou poverenja ',
        num2str(gamma), '.'])
33 end
34
35 figure
36 plot(y_jm_hat, res_jm, 'b*')
37 xlabel('Ocena procenta zauzetih sedista jednostrukog
        linearnog modela')
38 ylabel('Reziduali jednostrukog linearnog modela')
39 title('Dijagram rasipanja reziduala u odnosu na ocenu
        procenta zauzetih sedista')
40
41 deg_fr = n - size(beta_jm_hat, 1);
42 S2_jm = RSS_jm / deg_fr;
43 SX5X5 = sum((X5 - mean(X5)) .^ 2);
44 q_jm = tinv(1 - alpha / 2, deg_fr);
45 pm_ci_beta_jm_0 = q_jm * sqrt(S2_jm * sum(X5 .^ 2) /
        (SX5X5 * n));
46 ci_beta_jm_0 = [beta_jm_hat(1) - pm_ci_beta_jm_0,
        beta_jm_hat(1) + pm_ci_beta_jm_0];
47 disp(['Interval poverenja za koeficijent beta_0
```

A MATLAB KOD

```
jednostrukog linearnog modela, na nivou poverenja
', num2str(gamma), ', je: [' ,
num2str(ci_beta_jm_0(1)), ', ',
num2str(ci_beta_jm_0(2)), '].']]);
48
49 pm_ci_beta_jm_1 = q_jm * sqrt(S2_jm / SX5X5);
50 ci_beta_jm_1 = [beta_jm_hat(2) - pm_ci_beta_jm_1,
beta_jm_hat(2) + pm_ci_beta_jm_1];
51 disp(['Interval poverenja za koeficijent beta_1
jednostrukog linearnog modela, na nivou poverenja
', num2str(gamma), ', je: [' ,
num2str(ci_beta_jm_1(1)), ', ',
num2str(ci_beta_jm_1(2)), '].']]);
52
53 MSE_jm = RSS_jm / n;
54
55 Syy = sum((y - mean(y)) .^ 2);
56 R2_jm = 1 - RSS_jm / Syy;
57
58 % ---- Pun linearni model ----
59
60 X = [ones(n, 1) X];
61 rank_X = rank(X);
62
63 [beta_hat, y_hat, RSS] = lreg(X, y);
64 disp(['Jednacina visestruke linearne regresije za
procenat zauzetih sedista preko ostalih
promenljivih, tokom meseca, je Y = ',
num2str(beta_hat(1)), ' + ', num2str(beta_hat(2)),
' * x1 - ', num2str(abs(beta_hat(3))), ' * x2 + ',
num2str(beta_hat(4)), ' * x3 - ',
num2str(abs(beta_hat(5))), ' * x4 + ',
num2str(beta_hat(6)), ' * x5 - ',
num2str(abs(beta_hat(7))), ' * x6.']);
65
66 res = y - y_hat;
67 p = bptest(X, res);
68 if p < alpha
69     disp(['Reziduali punog linearnog modela nisu
homoskedasticni prema studentizovanom
Brus-Peiganovom testu na nivou poverenja ',
```

A MATLAB KOD

```
        num2str(gamma), '.')])
70 else
71     disp(['Reziduali punog linearnog modela su
        homoskedasticni prema studentizovanom
        Brus-Peiganovom testu na nivou poverenja ',
        num2str(gamma), '.'])
72 end
73
74 figure
75 plot(y_hat, res, 'b*')
76 xlabel('Ocena procenta zauzetih sedista punog
        linearnog modela')
77 ylabel('Reziduali punog linearnog modela')
78 title('Dijagram rasipanja reziduala u odnosu na ocenu
        procenta zauzeta')
79
80 MSE = RSS / n;
81 R2 = 1 - RSS / Syy;
82
83 % ---- Redukovani linearni model ----
84
85 [feat, beta_red_hat, y_red_hat, RSS_red] = ffsb(X, y,
        1, alpha);
86 disp(['Jednacina visestruke linearne regresije za
        procenat zauzetih sedista preko broja putnickih
        kilometara * 1000, broja sati letenja i broja
        putnika, tokom meseca, je Y = ',
        num2str(beta_red_hat(1)), ' + ',
        num2str(beta_red_hat(2)), ' * x5 - ',
        num2str(abs(beta_red_hat(3))), ' * x2 - ',
        num2str(abs(beta_red_hat(4))), ' * x4.'])
87 X_red = X(:, feat);
88
89 res_red = y - y_red_hat;
90 p_red = bptest(X_red, res_red);
91 if p_red < alpha
92     disp(['Reziduali redukovanog linearnog modela
        nisu homoskedasticni prema studentizovanom
        Brus-Peiganovom testu na nivou poverenja ',
        num2str(gamma), '.'])
93 else
```

A MATLAB KOD

```
94     disp(['Reziduali redukovanog linearnog modela su
           homoskedasticni prema studentizovanom
           Brus-Peiganovom testu na nivou poverenja ',
           num2str(gamma), '.'])
95 end
96
97 figure
98 plot(y_red_hat, res_red, 'b*')
99 xlabel('Ocena procenta zauzetih sedista redukovanog
        linearnog modela')
100 ylabel('Reziduali redukovanog linearnog modela')
101 title('Dijagram rasipanja reziduala u odnosu na ocenu
        procenta zauzetih sedista')
102
103 MSE_red = RSS_red / n;
104 R2_red = 1 - RSS_red / Syy;
105
106 deg_fr1 = size(X, 2) - size(X_red, 2);
107 deg_fr2 = n - size(X, 2);
108 F_reg = (RSS_red - RSS) / deg_fr1) / (RSS / deg_fr2);
109 q = finv(1 - alpha, deg_fr1, deg_fr2);
110 if F_reg > q
111     disp(['Prihvatamo hipotezu H1(beta_izb nije nula
           vektor), na nivou poverenja ', num2str(gamma),
           '.'])
112 else
113     disp(['Prihvatamo hipotezu H0(beta_izb je nula
           vektor), na nivou poverenja ', num2str(gamma),
           '.'])
114 end
115
116 % ---- Nelinearni modeli ----
117
118 f_jm = @(b) 100 ./ (1 + exp(-(X_jm * b)));
119
120 beta_jmnl_hat = zeros(size(X_jm, 2), 1);
121 h = 1e-11;
122 max_iter = 100;
123 stop = 1e-11;
124 [beta_jmnl_hat, n_iter_jm, y_jmnl_hat, RSS_jmnl] =
    gn(y, f_jm, beta_jmnl_hat, h, max_iter, stop);
```

A MATLAB KOD

```
125 disp(['Jednacina jednostruke nelinearne regresije za
        procenat zauzetih sedista preko broja putnickih
        kilometara * 1000, tokom meseca, je Y = 100 / (1 +
        exp(-(' , num2str(beta_jmnl_hat(1)), ' + ',
        num2str(beta_jmnl_hat(2)), ' * x5))).']);
126
127 figure
128 plot(X5, y, 'b*')
129 hold on
130 xv = (min(X5):7000:max(X5))';
131 plot(xv, 100 ./ (1 + exp(-([ones(size(xv, 1), 1) xv]
        * beta_jmnl_hat))), 'r')
132 xlabel('Broj putnickih kilometara u hiljadama')
133 ylabel('Procenat zauzetih sedista')
134 title(['Dijagram rasipanja i regresiona kriva y = 100
        / (1 + exp(-(' , num2str(beta_jmnl_hat(1)), ' + ',
        num2str(beta_jmnl_hat(2)), ' * x))').'])
135 hold off
136
137 MSE_jmnl = RSS_jmnl / n;
138
139 f = @(b) 100 ./ (1 + exp(-(X * b)));
140 f_red = @(b) 100 ./ (1 + exp(-(X_red * b)));
141
142 beta_nl_hat = zeros(size(X, 2), 1);
143 [beta_nl_hat, n_iter, y_nl_hat, RSS_nl] = gn(y, f,
        beta_nl_hat, h, max_iter, stop);
144 disp(['Jednacina visestruke nelinearne regresije za
        procenat zauzetih sedista preko ostalih
        promenljivih, tokom meseca, je Y = 100 / (1 +
        exp(-(' , num2str(beta_nl_hat(1)), ' + ',
        num2str(beta_nl_hat(2)), ' * x1 - ',
        num2str(abs(beta_nl_hat(3))), ' * x2 + ',
        num2str(beta_nl_hat(4)), ' * x3 - ',
        num2str(abs(beta_nl_hat(5))), ' * x4 + ',
        num2str(beta_nl_hat(6)), ' * x5 - ',
        num2str(abs(beta_nl_hat(7))), ' * x6))).']);
145 beta_rednl_hat = zeros(size(X_red, 2), 1);
146 [beta_rednl_hat, n_iter_red, y_rednl_hat, RSS_rednl]
        = gn(y, f_red, beta_rednl_hat, h, max_iter, stop);
147 disp(['Jednacina visestruke nelinearne regresije za
```

A MATLAB KOD

```
    procenat zauzetih sedista preko broja putnickih
    kilometara * 1000, broja sati letenja i broja
    putnika, tokom meseca, je Y = 100 / (1 + exp(-('
    num2str(beta_rednl_hat(1)), ' + ',
    num2str(beta_rednl_hat(2)), ' * x5 - ',
    num2str(abs(beta_rednl_hat(3))), ' * x2 - ',
    num2str(abs(beta_rednl_hat(4))), ' * x4))).')]');
148
149 MSE_n1 = RSS_n1 / n;
150 MSE_redn1 = RSS_redn1 / n;
151
152 X_red2 = X_red(:, 2:end);
153 f_red2 = @(b) 100 ./ (1 + exp(-(X_red2 * b)));
154
155 beta_red2nl_hat = zeros(size(X_red2, 2), 1);
156 [beta_red2nl_hat, n_iter_red2, y_red2nl_hat,
    RSS_red2nl] = gn(y, f_red2, beta_red2nl_hat, h,
    max_iter, stop);
157 disp(['Jednacina visestruke nelinearne regresije bez
    slobodnog clana za procenat zauzetih sedista preko
    broja putnickih kilometara * 1000, broja sati
    letenja i broja putnika, tokom meseca, je Y = 100
    / (1 + exp(-(' , num2str(beta_red2nl_hat(1)), ' * x5
    - ', num2str(abs(beta_red2nl_hat(2))), ' * x2 - ',
    num2str(abs(beta_red2nl_hat(3))), ' * x4))).')]');
158
159 MSE_red2nl = RSS_red2nl / n;
160
161 % ---- Trening i testiranje ----
162
163 trening_size = 0.7;
164 tt_iter = 1000;
165
166 n_trening = round(trening_size * n);
167 n_test = n - n_trening;
168 nv = 1:n;
169
170 MSE_test = NaN(tt_iter, 7);
171 for i = 1:tt_iter
172     tren_rows = randsample(n, n_trening);
173     test_rows = setdiff(nv, tren_rows);
```


A MATLAB KOD

```
174
175     X_jm_tren = X_jm(tren_rows, :);
176     X_tren = X(tren_rows, :);
177     X_red_tren = X_red(tren_rows, :);
178     X_red2_tren = X_red2(tren_rows, :);
179     f_jm_tren = @(b) 100 ./ (1 + exp(-(X_jm_tren *
        b)));
180     f_tren = @(b) 100 ./ (1 + exp(-(X_tren * b)));
181     f_red_tren = @(b) 100 ./ (1 + exp(-(X_red_tren *
        b)));
182     f_red2_tren = @(b) 100 ./ (1 + exp(-(X_red2_tren
        * b)));
183     y_tren = y(tren_rows, :);
184
185     beta_jm_tren = lreg(X_jm_tren, y_tren);
186     beta_tren = lreg(X_tren, y_tren);
187     beta_red_tren = lreg(X_red_tren, y_tren);
188     beta_jmnl_tren = zeros(size(X_jm_tren, 2), 1);
189     beta_jmnl_tren = gn(y_tren, f_jm_tren,
        beta_jmnl_tren, h, max_iter, stop);
190     beta_nl_tren = zeros(size(X_tren, 2), 1);
191     beta_nl_tren = gn(y_tren, f_tren, beta_nl_tren,
        h, max_iter, stop);
192     beta_rednl_tren = zeros(size(X_red_tren, 2), 1);
193     beta_rednl_tren = gn(y_tren, f_red_tren,
        beta_rednl_tren, h, max_iter, stop);
194     beta_red2nl_tren = zeros(size(X_red2_tren, 2), 1);
195     beta_red2nl_tren = gn(y_tren, f_red2_tren,
        beta_red2nl_tren, h, max_iter, stop);
196
197     X_jm_test = X_jm(test_rows, :);
198     X_test = X(test_rows, :);
199     X_red_test = X_red(test_rows, :);
200     X_red2_test = X_red2(test_rows, :);
201     f_jm_test = @(b) 100 ./ (1 + exp(-(X_jm_test *
        b)));
202     f_test = @(b) 100 ./ (1 + exp(-(X_test * b)));
203     f_red_test = @(b) 100 ./ (1 + exp(-(X_red_test *
        b)));
204     f_red2_test = @(b) 100 ./ (1 + exp(-(X_red2_test
        * b)));
```

A MATLAB KOD

```
205     y_test = y(test_rows, :);
206
207     MSE_test(i, 1) = sum((y_test - X_jm_test *
208         beta_jm_tren) .^ 2) / n_test;
209     MSE_test(i, 2) = sum((y_test - X_test *
210         beta_tren) .^ 2) / n_test;
211     MSE_test(i, 3) = sum((y_test - X_red_test *
212         beta_red_tren) .^ 2) / n_test;
213     MSE_test(i, 4) = sum((y_test -
214         f_jm_test(beta_jmnl_tren)) .^ 2) / n_test;
215     MSE_test(i, 5) = sum((y_test -
216         f_test(beta_nl_tren)) .^ 2) / n_test;
217     MSE_test(i, 6) = sum((y_test -
218         f_red_test(beta_rednl_tren)) .^ 2) / n_test;
219     MSE_test(i, 7) = sum((y_test -
220         f_red2_test(beta_red2nl_tren)) .^ 2) / n_test;
221 end
222
223 mean_MSE_test = mean(MSE_test);
```

Algoritam A.11: Projekat_Regresija.m

Dodatak B Osnovna tvrđenja

U ovom dodatku su dokazana neka od često korišćenih osnovnih tvrđenja o linearnoj regresiji.

Teorema B.1. *Neka je X matrica čije su kolone vektori X_j koji su uzorci odgovarajućih nezavisnih promenljivih x_j , $j \in \{1, 2, \dots, k\}$, za uzorak veličine n , vektor y odgovarajući uzorak zavisne promenljive Y , ε slučajna greška i $\beta = [\beta_1 \ \beta_2 \ \dots \ \beta_k]^T$ vektor parametara linearnog modela*

$$Y = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k + \varepsilon,$$

koji je ocenjen pomoću $\hat{y} = X\hat{\beta}$. Ako je rang matrice X jednak k , onda postoji jedinstvena ocena $\hat{\beta}$ parametra β dobijena metodom najmanjih kvadrata, tj. minimizacijom sume kvadrata reziduala

$$RSS = \sum_{i=1}^n \hat{\varepsilon}_i^2,$$

gde je $\hat{\varepsilon}_i$ i -ta vrednost vektora reziduala $\hat{\varepsilon} = y - \hat{y}$, $i \in \{1, 2, \dots, n\}$. Pritom važi

$$\hat{\beta} = (X^T X)^{-1} X^T y.$$

Dokaz. Kako je $\hat{\varepsilon} = y - X\hat{\beta}$, to je

$$RSS = \sum_{i=1}^n \hat{\varepsilon}_i^2 = \hat{\varepsilon}^T \hat{\varepsilon} = (y - X\hat{\beta})^T (y - X\hat{\beta}).$$

Dakle, treba naći minimum funkcije $f(\beta) = (y - X\beta)^T (y - X\beta)$. U tom cilju se traži β za koje važi $\nabla f(\beta) = 0_{k \times 1}$. Računanjem se dobija da je

$$\begin{aligned} f(\beta) &= (y - X\beta)^T (y - X\beta) \\ &= (y^T - (X\beta)^T)(y - X\beta) \\ &= (y^T - \beta^T X^T)(y - X\beta) \\ &= y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X\beta. \end{aligned}$$

Pošto su $y^T X\beta$ i $\beta^T X^T y$ skalari i važi $(y^T X\beta)^T = \beta^T X^T y$, oni su jednaki, pa je

$$f(\beta) = y^T y - 2\beta^T X^T y + \beta^T X^T X\beta.$$

Odatle sledi da je

$$\begin{aligned}\nabla f(\beta) &= \nabla(y^T y - 2\beta^T X^T y + \beta^T X^T X \beta) \\ &= -2X^T y + 2X^T X \beta,\end{aligned}$$

jer je $X^T y$ vektor i $X^T X$ simetrična matrica. Zaista, važi

$$(X^T X)^T = X^T (X^T)^T = X^T X,$$

pa je matrica $X^T X$ simetrična. Dalje, treba da važi

$$\begin{aligned}\nabla f(\beta) &= 0_{k \times 1}, \\ -2X^T y + 2X^T X \beta &= 0_{k \times 1}, \\ (X^T X)\beta &= X^T y,\end{aligned}$$

odakle se dobija jedinstveno

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} f(\beta) = (X^T X)^{-1} X^T y,$$

ako je $\nabla^2 f(\beta) = 2X^T X$ pozitivno-definitna matrica i postoji $(X^T X)^{-1}$. Kako je svaka pozitivno-definitna matrica invertibilna i 2 pozitivna konstanta, dovoljno je dokazati da je $X^T X$ pozitivno-definitna matrica.

Neka je v proizvoljan nenula vektor dimenzije $k \times 1$. Tada je proizvod Xv linearna kombinacija kolona matrice X . Kako je rang matrice X jednak k , njene kolone su linearno nezavisne, pa je $w = Xv \neq 0_{n \times 1}$. Odavde sledi da je

$$v^T X^T X v = (Xv)^T Xv = w^T w = \sum_{i=1}^n w_i^2 > 0,$$

gde je w_i i -ta vrednost vektora w , $i \in \{1, 2, \dots, n\}$. Stoga, matrica $X^T X$ jeste pozitivno-definitna. $\square$

Lema B.2. *Uz pretpostavke prethodne teoreme važi:*

- (i) $X^T \hat{\varepsilon} = 0_{k \times 1}$,
- (ii) $\hat{y}^T \hat{\varepsilon} = 0$,
- (iii) $\hat{y}^T \hat{y} = y^T y$.

B OSNOVNA TVRĐENJA

Dokaz. (i) Na osnovu prethodne teoreme i $y = \hat{y} + \hat{\varepsilon} = X\hat{\beta} + \hat{\varepsilon}$ je

$$\begin{aligned}(X^T X)\hat{\beta} &= X^T y, \\ X^T X\hat{\beta} &= X^T (X\hat{\beta} + \hat{\varepsilon}), \\ X^T X\hat{\beta} &= X^T X\hat{\beta} + X^T \hat{\varepsilon}, \\ 0_{k \times 1} &= X^T \hat{\varepsilon}.\end{aligned}$$

$$(ii) \quad \hat{y}^T \hat{\varepsilon} = (X\hat{\beta})^T \hat{\varepsilon} = (\hat{\beta}^T X^T) \hat{\varepsilon} = \hat{\beta}^T (X^T \hat{\varepsilon}) = \hat{\beta}^T 0_{k \times 1} = 0.$$

$$\begin{aligned}(iii) \quad \hat{y}^T \hat{y} &= (X\hat{\beta})^T (X\hat{\beta}) \\ &= (X(X^T X)^{-1} X^T y)^T X(X^T X)^{-1} X^T y \\ &= y^T X(X^T X)^{-1} (X^T X) (X^T X)^{-1} X^T y \\ &= y^T (X(X^T X)^{-1} X^T y) \\ &= y^T \hat{y}.\end{aligned}$$

□

Posledica B.3. *Dodatno, neka jedna od kolona matrice X odgovara odsečku, tj. jednaka je $1_{n \times 1}$. Tada važi:*

- (a) *suma reziduala je nula,*
- (b) *aritmetička sredina reziduala, u oznaci $\bar{\hat{\varepsilon}}$, je nula,*
- (c) *suma vrednosti uzorka zavisne promenljive je jednaka sumi vrednosti njene ocene,*
- (d) *aritmetičke sredine vrednosti uzorka zavisne promenljive i njene ocene, u oznakama $\bar{y}$ i $\bar{\hat{y}}$, respektivno, su jednake,*
- (e) *regresiona hiperravan prolazi kroz tačku čije su koordinate aritmetičke sredine uzorka datih promenljivih,*
- (f) *uzoračke kovarijanse između uzorka nezavisnih promenljivih i vektora reziduala su nula,*
- (g) *uzoračka kovarijanse između ocena uzorka zavisne promenljive i vektora reziduala je nula,*
- (h) *ukupna suma kvadrata,*

$$TSS = \sum_{i=1}^n (y_i - \bar{y})^2,$$

B OSNOVNA TVRĐENJA

gde je y_i i -ta vrednost vektora y , je jednaka zbiru sume kvadrata reziduala i objašnjene sume kvadrata,

$$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2,$$

gde je $\hat{y}_i$ i -ta vrednost vektora $\hat{y}$.

- (i) Posmatraju se dva linearna modela sa odsečkom za isto y . Neka su koeficijenti determinacije definisani sa $R_a^2 = ESS_a/TSS$ i $R_b^2 = ESS_b/TSS$ za $y \neq c_{n \times 1}$, $c \in \mathbb{R}$, gde su ESS_a i ESS_b objašnjene sume kvadrata prvog i drugog modela, respektivno, i TSS ukupna suma kvadrata. Tada je $R_b^2 \geq R_a^2$ ako i samo ako je $RSS_b \leq RSS_a$, gde su RSS_a i RSS_b sume kvadrata reziduala prvog i drugog modela, respektivno.

Dokaz. (a) Odgovarajuća vrsta matrice X^T je jednaka $1_{1 \times n}$, pa je ista vrsta vektora $X^T \hat{\varepsilon}$ jednaka sumi reziduala. Sada iz Leme B.2 (i) sledi traženo.

(b) Podeliti rezultat pod (a) sa n .

(c) Kako je $\hat{\varepsilon} = y - \hat{y}$, sumiranjem te jednakosti, pa primenom rezultata pod (a), dobija se traženo tvrđenje.

(d) Podeliti rezultat pod (c) sa n .

(e) Kako je $\hat{\varepsilon} = y - X\hat{\beta}$, sumiranje i deljenjem te jednakosti sa n , pa primenom rezultata pod (b), dobija se traženo tvrđenje.

(f) Važi

$$\sum_{i=1}^n (X_{ij} - \bar{X}_j)(\hat{\varepsilon}_i - \bar{\varepsilon}) = \sum_{i=1}^n X_{ij}\hat{\varepsilon}_i - n\bar{X}_j\bar{\varepsilon}, \quad j \in \{1, 2, \dots, k\},$$

gde je X_{ij} i -ta vrednost vektora X_j , $i \in \{1, 2, \dots, n\}$, i $\bar{X}_j$ njegova aritmetička sredina, $j \in \{1, 2, \dots, k\}$, pa tvrđenje sledi iz Leme B.2 (i) i rezultata pod (b).

(g) Važi

$$\sum_{i=1}^n (\hat{y}_i - \bar{y})(\hat{\varepsilon}_i - \bar{\varepsilon}) = \sum_{i=1}^n \hat{y}_i \hat{\varepsilon}_i - n\bar{y}\bar{\varepsilon},$$

pa tvrđenje sledi iz Leme B.2 (ii) i rezultata pod (b).

(h) Koristeći vektorski zapis, dobija se da je

$$\begin{aligned}
 TSS &= \|y - \bar{y}_{n \times 1}\|_2^2 \\
 &= \|y - \hat{y} + \hat{y} - \bar{y}_{n \times 1}\|_2^2 \\
 &= \|y - \hat{y}\|_2^2 + 2\langle y - \hat{y} \mid \hat{y} - \bar{y}_{n \times 1} \rangle + \|\hat{y} - \bar{y}_{n \times 1}\|_2^2 \\
 &= RSS + 2(y^T \hat{y} - y^T \bar{y}_{n \times 1} - \hat{y}^T \hat{y} + \hat{y}^T \bar{y}_{n \times 1}) + ESS,
 \end{aligned}$$

pa iz Leme B.2 (iii) sledi da je

$$\begin{aligned}
 TSS &= RSS + 2(\hat{y} - y)^T \bar{y}_{n \times 1} + ESS \\
 &= RSS - 2\hat{\epsilon}^T 1_{n \times 1} \bar{y} + ESS.
 \end{aligned}$$

Sada na osnovu rezultata pod (a) sledi traženo.

- (i) Ako je $y \neq c_{n \times 1}$, $c \in \mathbb{R}$, onda je $y \neq \bar{y}_{n \times 1}$, pa je $TSS > 0$. Dakle, koeficijenti determinacije su dobro definisani. Dalje, na osnovu rezultata pod (h) važi $R_a^2 = ESS_a/TSS = (TSS - RSS_a)/TSS = 1 - RSS_a/TSS$ i, analogno, $R_b^2 = 1 - RSS_b/TSS$. Stoga je $R_b^2 \geq R_a^2$ ako i samo ako je $RSS_b \leq RSS_a$. $\square$

Stav B.4. *Posmatra se linearni model iz Teoreme B.1 uz iste pretpostavke. Neka je matrici X zdesna dodat vektor tako da je rang novodobijene matrice X_c jednak $k + 1$. Tada za novodobijeni linearan model postoji jedinstvena ocena $\hat{\beta}_c$ parametra β_c dobijena metodom najmanjih kvadrata i pritom je $RSS_c \leq RSS$, gde je RSS suma kvadrata reziduala polaznog modela, a RSS_c suma kvadrata reziduala novodobijenog modela.*

Dokaz. Prema Teoremi B.1 postoji jedinstvena ocena $\hat{\beta}_c$ parametra β_c dobijena metodom najmanjih kvadrata. Neka je RSS_d suma kvadrata reziduala novodobijenog linearnog modela gde je za ocenu parametra β_c uzet vektor $\hat{\beta}_d = [\hat{\beta}^T \ 0]^T$. Tada je $X_c \hat{\beta}_d = X \hat{\beta}$, pa je $RSS_d = RSS$. S druge strane, zbog primene metode najmanjih kvadrata važi $RSS_c \leq RSS_d$, jer je

$$RSS_c = \min_{\beta_c} (y - X_c \beta_c)^T (y - X_c \beta_c).$$

Dakle, važi $RSS_c \leq RSS_d = RSS$. $\square$

Posledica B.5. *Dodatno, neka jedna od kolona matrice X odgovara odsečku i $y \neq c_{n \times 1}$, $c \in \mathbb{R}$. Tada je $R_c^2 \geq R^2$, gde su R^2 i R_c^2 koeficijenti determinacije polaznog i novodobijenog modela, respektivno.*

Dokaz. Tvrđenje sledi iz prethodnog stava i Posledice B.3 (i). $\square$

Literatura

- [1] T. S. Breusch, A. R. Pagan, *A Simple Test for Heteroskedasticity and Random Coefficient Variation*, in *Econometrica*, Wiley-Blackwell, **47**(5):1287–1294, 1979. doi:10.2307/1911963.
- [2] J. Brownlee, *Train-Test Split for Evaluating Machine Learning Algorithms*, <https://machinelearningmastery.com/train-test-split-for-evaluating-machine-learning-algorithms/>. Accessed 18 Sep. 2023.
- [3] Cross Validated, *About feature-selection*, <https://stats.stackexchange.com/tags/feature-selection/info>. Accessed 18 Sep. 2023.
- [4] M. Floater, *Lecture 13: Non-linear least squares and the Gauss-Newton method*, <https://www.uio.no/studier/emner/matnat/math/MAT3110/h19/undervisningsmateriale/lecture13.pdf>. Accessed 18 Sep. 2023.
- [5] R. Koenker, *A note on studentizing a test for heteroscedasticity*, in *Journal of Econometrics*, Elsevier, **17**(1):107–112, 1981. doi:10.1016/0304-4076(81)90062-2.
- [6] K.-L. Lai, J. L. Crassidis, *Extensions of the first and second complex-step derivative approximations*, in *Journal of Computational and Applied Mathematics*, Elsevier, **219**(1):276–293, 2008. doi:10.1016/j.cam.2007.07.026.
- [7] K. Rice, *Sprint research runs into a credibility gap*, in *Nature*, **432**:147, 2004. doi:10.1038/432147b.
- [8] D. Waldman, *A note on algebraic equivalence of White’s test and a variation of the Godfrey/Breusch-Pagan test for heteroscedasticity*, in *Economics Letters*, Elsevier, **13**(2–3):197–200, 1983. doi:10.1016/0165-1765(83)90085-X.
- [9] H. White, *A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity*, in *Econometrica*, Wiley-Blackwell, **48**(4):817–838, 1980. doi:10.2307/1912934.